



(12) 发明专利申请

(10) 申请公布号 CN 120654894 A

(43) 申请公布日 2025. 09. 16

(21) 申请号 202510836788.8

G06N 3/048 (2023.01)

(22) 申请日 2025.06.22

G06N 3/084 (2023.01)

(71) 申请人 新疆大学

G06F 18/21 (2023.01)

地址 830046 新疆维吾尔自治区乌鲁木齐市天山区胜利路666号

G06F 18/23213 (2023.01)

(72) 发明人 赵洪田 王一权 闫佳瑶 雷子涵
常钰晗 张佳琳

(51) Int. Cl.

G06Q 10/04 (2023.01)

G06Q 50/26 (2024.01)

G06N 3/045 (2023.01)

G06F 18/214 (2023.01)

G06F 18/24 (2023.01)

G06F 18/22 (2023.01)

G06N 3/082 (2023.01)

G06F 18/243 (2023.01)

权利要求书1页 说明书6页 附图4页

(54) 发明名称

一种基于多层感知机 (MLP) 模型的洪水灾害
预测方法

(57) 摘要

本发明公开了一种基于多层感知机 (MLP) 模型的洪水灾害预测方法及系统,通过数据预处理、特征选择、模型优化等步骤,构建了一种高效的洪水预测模型。该方法能够显著提高洪水预测的准确性,增强模型的泛化能力,并通过K-means 聚类算法和权重评分模型量化评估洪水事件的风险级别。本发明为洪水灾害的早期预警和风险评估提供了科学依据,具有广泛的应用前景。

1. 一种基于多层感知机 (MLP) 模型的洪水灾害预测方法, 主要包括以下步骤:

S1. 数据预处理

用于对洪水灾害数据集进行预处理, 包括缺失值处理、异常值检测和数据标准化;

S2. 特征选择

计算Spearman相关系数, 同时运用因子分析和决策树模型进行降维处理, 通过此方式可以明确洪水灾难的关键影响元素, 并据此提出应对洪水问题的对策和建议;

S3. 模型构建与训练

用于构建多层感知机 (MLP) 模型, 使用L2正则化技术对模型进行优化;

S4. 模型评估与优化

用于使用均方误差和决定系数 (R^2) 作为模型的评估指标, 评估模型的预测性能;

S5. 洪水风险等级划分

用于使用K-means聚类算法将洪水事件划分为高、中、低三个风险等级;

S6. 洪水预测与可视化

用于使用训练好的MLP模型对测试数据集进行洪水发生概率的预测, 并通过直方图和折线图对预测结果进行可视化展示。

2. 根据权利要求1所述的算法, 其特征在于:

(1) 步骤S1中包括使用箱线图、直方图和核密度估计图识别并处理数据中的异常值和噪声;

(2) 步骤S2中包括使用逐步回归和特征选择算法, 进一步优化特征集, 减少冗余特征;

(3) 步骤S3中MLP模型的隐藏层神经元数量分别为64和32, 激活函数采用ReLU函数, 优化器采用Adam优化器;

(4) 步骤S4对模型进行灵敏度分析, 评估不同特征对模型预测结果的影响;

(5) 步骤S5中包括构建权重评分模型, 量化评估每个洪水事件的风险级别;

(6) 步骤S6包括使用Shapiro-Wilk检验方法对预测数据的分布特性进行正态性检验。

一种基于多层感知机 (MLP) 模型的洪水灾害预测方法

技术领域

[0001] 本发明涉及洪水灾害预测技术领域,尤其涉及一种基于多层感知机 (MLP) 模型的洪水灾害预测方法,适用于洪水灾害的早期预警和风险评估。

背景技术

[0002] 洪水灾害,作为一类由自然环境触发的重大灾害,以其高发性、破坏力强和广泛的影响区域而著称。随着全球气温上升,洪水灾害的发生频率和强度呈上升趋势,给给人类社会和生态环境带来了巨大的威胁。

[0003] 近年来,随着机器学习技术的快速发展,基于机器学习的洪水预测方法逐渐成为研究热点。现有算法虽然能够处理高维数据,并捕捉复杂的非线性关系,但是在特征选择方面较为简单,难以有效筛选出对洪水发生概率影响最大的关键特征,导致模型的预测精度有限。部分算法(如SVM)在处理大规模数据时计算复杂度较高,难以满足实时预测的需求。

[0004] 针对现有算法的不足,本发明提出了一种基于多层感知机 (MLP) 模型的洪水灾害预测方法及系统,不仅能够显著提高洪水预测的准确性,还能够为政府和相关部门提供科学的决策支持,减少洪水灾害带来的损失。

发明内容

[0005] 本发明包含数据预处理模块,特征选择模块,模型构建与训练模块,模型评估与优化模块,洪水风险等级划分模块以及洪水预测与可视化模块。

[0006] 一种基于多层感知机 (MLP) 模型的洪水灾害预测方法,主要包括以下步骤:

[0007] S1:数据预处理

[0008] 缺失值处理:对洪水灾害数据集进行缺失值检测,借助Python和MATLAB并结合find函数深度查找处理缺失值。为了更加直观地展示缺失项的分布情况,我们还生成缺失值数量的直方图,直观展示缺失值的分布情况。结果表明,数据集中并无缺失值存在。

[0009] 异常值检测与处理:使用箱线图和核密度 (KDE) 估计图识别数据中的异常值。通过计算每个特征指标的范围,删除特征值属性大于10的数据行,确保数据的准确性。

[0010] 数据可视化:通过直方图和核密度 (KDE) 估计图展示数据的分布情况,识别出数据的多峰分布特性,为后续的数据分析工作提供指导意义。

[0011] S2:特征选择

[0012] 相关性分析:使用Spearman相关系数计算各特征指标与洪水发生概率的相关性,生成Spearman相关性矩阵热力图和柱形图,筛选出与洪水发生概率高度相关的特征指标。将经过预处理的数据构图为线性回归散点图,通过线性回归分析,进一步验证各特征指标与洪水发生概率之间的线性关系。

[0013] 因子分析:使用因子分析技术从原始特征中提取共性因子,简化数据的解释和理解过程。通过因子载荷矩阵,识别出对洪水发生概率影响最大的关键因子。生成因子载荷矩阵的热力图,直观展示各因子对洪水发生概率的影响。

[0014] 决策树分析:使用决策树模型进行特征重要性分析,识别出对洪水发生概率影响最大的关键特征。采取后剪枝策略,提升了模型的泛化性能并降低了其复杂度。生成特征重要性柱状图,直观展示各特征对洪水发生概率的影响。

[0015] S3:模型构建与训练

[0016] 模型构建:构建多层感知机 (MLP) 模型,流程包含输入层、隐藏层和输出层。隐藏层的神经元数量分别为64和32,激活函数采用ReLU函数,优化器采用Adam优化器。规定最大迭代次数为500,以此保证模型能够充分掌握数据特性。

[0017] 模型训练:将数据集按照8比2的比例划分为训练集与验证集,确保模型在训练过程中能够充分学习数据的内在规律,同时又能通过验证集来评估模型的泛化能力,避免过拟合现象的发生。使用均方误差和决定系数 (R^2) 作为评估回归模型贴合程度的评价指标。

[0018] 模型优化:采用L2正则化策略以进一步提升模型的性能与泛化能力。

[0019] S4:洪水风险等级划分

[0020] K-means聚类分析:应用K-means聚类分析,将各事件中洪水发生概率聚类成高、中、低风险三个类别。通过计算每个聚类中心的均值,识别出不同风险等级的特征分布。生成聚类结果的散点图,直观展示不同风险等级的洪水事件分布。

[0021] 特征重要性分析:利用随机森林算法评估各种指标的重要性,明确洪水影响因素的重要性等级。根据基于聚类分析的特征聚类均值图可视化了各个特征在聚类分析中的具体表现。生成重要特征雷达图,直观展示不同风险等级的关键特征分布,实现对洪水风险的多维度综合评估。

[0022] 灵敏度分析:对初始构建的预测模型行灵敏度分析,评估不同特征权重对模型预测结果的影响,识别出对洪水预测最具决定性的关键特征。通过调整特征权重,进一步优化模型的预测精度和稳定性。

[0023] S5:洪水预测与可视化

[0024] 用于使用训练好的MLP模型对测试数据集进行洪水发生概率的预测,并通过直方图和折线图对预测结果进行可视化展示。

[0025] 使用Shapiro-Wilk正态性检验方法对预测数据的分布特性进行检验,确保预测结果的可靠性。

有益效果

[0026] 本发明通过多层感知机 (MLP) 神经网络构建洪水灾害预测模型,精准捕捉洪水发生概率与多种因素之间的复杂非线性关系,显著提升预测精度。结合K-means聚和随机森林算法,实现洪水风险的精细化分级与评估,为洪水灾害的防控提供科学依据,助力提前制定合理应对策略,有效降低洪水灾害损失。

[0027] 本发明的洪水灾害预测模型具有广泛的适用性,能够基于特定区域的数据进行深度分析,为不同地区的洪水预警提供支持。其核心数据处理与分析技术,包括数据预处理、特征选择、模型训练与优化等,为提升预测准确性提供了坚实保障。同时,该模型与地理信息系统 (GIS) 技术的融合,可实现对不同地区洪水风险的精细化评估,为城市规划和灾害管理提供有力支撑,展现出强大的推广潜力和实用价值。

附图说明

[0028] 图1为本发明一种基于多层感知机 (MLP) 模型的洪水灾害预测方法示意图;

[0029] 图2为本发明一种基于多层感知机 (MLP) 模型的洪水灾害预测方法的算法详细步骤图。

具体实施

[0030] 为了使本发明的目的、技术方案及优点更加清楚明白,下面结合附图和具体实施例对本发明做进一步说明。应当理解,此处所描述的具体实施例仅用以解释本发明,并不用于限定本发明。基于本发明中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于本发明保护的范围。

[0031] 一种基于多层感知机 (MLP) 模型的洪水灾害预测方法及系统,包括以下步骤:

[0032] S1.数据预处理:

[0033] 步骤(1)缺失值处理:

[0034] 检查缺失值:使用Python的isnull()函数和sum()函数统计每个特征的缺失值数量,并通过可视化工具展示缺失值分布情况。

[0035] 处理缺失值:根据数据集的实际情况,采用适当的方法处理缺失值。例如,如果缺失值较少,可以直接删除包含缺失值的行;如果缺失值较多,则可以考虑使用均值、中位数或众数等方法进行填充。在本研究中,经过检查发现数据集中并无缺失值,因此无需进一步的填补措施。

[0036] 步骤(2)异常值检测

[0037] 绘制箱线图:利用箱线图直观地展示每个特征的分布情况,包括中位数、四分位数和异常值。通过箱线图可以清晰地识别出数据中的异常值。

[0038] 计算数值范围:根据箱线图的四分位距 (IQR),计算每个特征的数值范围,并识别出超出正常范围的异常值。在本研究中,发现部分特征的数值范围较大,且存在个别大于18的异常值,因此删除了特征属性值大于18的所有对应的行。

[0039] S2.特征选择

[0040] 特征选择的目的是从众多特征中筛选出对洪水发生概率具有显著影响的关键特征,从而提高模型的预测能力和解释性。

[0041] 步骤(1)计算Spearman相关系数

[0042] 相关性分析:使用Spearman相关系数计算各特征与洪水发生概率之间的相关性。Spearman相关系数适用于非正态分布的数据,能够有效衡量变量之间的单调关系。通过计算得到的相关系数矩阵,可以直观地观察到各特征与洪水发生概率之间的相关性大小。Spearman相关系数的绝对值越趋近1,意味着相关性越强烈。反之,若趋近0,则表示相关性减弱。

Spearman相关系数 ρ 计算公式为

$$\rho = 1 - \frac{6\sum d_i^2}{n(n^2 - 1)}$$

[0043] 可视化相关性:将相关系数矩阵以热力图的形式进行可视化展示,颜色越暖表示相关性越强,颜色越冷表示相关性越弱。同时,还可以通过柱形图展示各特征与洪水发生概

率的相关性大小,以便更直观地识别出关键特征。

[0044] 步骤(2)因子提取

[0045] 共性因子:因子分析是一种降维技术,通过提取共性因子来简化数据结构。将各特征指标简化为较少的因子,从而揭示数据中潜在的模式或结构。在本研究中,通过因子分析提取了五个因子,并绘制了因子载荷矩阵,以展示每个因子在各个特征上的载荷情况。

[0046] 选择重要特征:根据因子载荷矩阵,选择在各因子上载荷较高的特征作为重要特征。这些特征在解释数据变异性和相关性方面具有重要作用,可以作为后续模型构建的关键输入变量。

[0047] 步骤(3)决策树模型

[0048] 构建决策树:决策树模型通过递归地将数据集分割成更小的子集,以最小化分类错误或预测误差。在本研究中,使用决策树模型对数据进行分类,并通过后剪枝策略优化模型,降低模型复杂度和过拟合风险。

[0049] 评估特征重要性:决策树模型可以输出特征重要性排序,通过分析决策树的结构和特征重要性,识别出对洪水发生概率影响较大的特征。在本研究中,发现无效防灾、地形排水、大坝质量等特征对洪水发生概率具有显著影响。

[0050] S3.模型构建与训练

[0051] 多层感知机(MLP)模型是一种前馈神经网络,能够学习输入特征与输出目标之间的复杂非线性关系。

[0052] 步骤(1)构建MLP模型

[0053] 模型架构设计:设计MLP模型的架构,包括输入层、隐藏层和输出层。在本研究中,模型设置了两个隐藏层,神经元数量分别为64和32,采用ReLU激活函数,以增强模型的非线性学习能力。神经元:包含一个带有权重和偏置的线性变换,以及一个激活函数(通常,输入层不使用激活函数,隐藏层和输出层使用激活函数)用来引入非线性,使得神经网络可以任意逼近任何非线性函数,这样神经网络就可以利用到更多的非线性模型中。隐藏层神经元:假设输入层用向量 $\vec{x}$ 表示,则隐藏层的输出就是 $f(w_1 \times \vec{x} + b_1)$,函数 f 可以是sigmoid函数或者tanh函数, w_1 是权重(连接系数), b_1 是偏置。

[0054] 输出层的输出: $\text{softmax}(w_2 \times x_1 + b_2)$, x_1 是隐藏层的输出。数据从输入层经过多个隐藏层的非线性变换,最后到达输出层进行分类或回归操作,完成MLP训练过程。

[0055] 选择优化器:选择合适的优化器用于模型的权重更新。在本研究中,使用Adam优化器,它结合了动量法和RMSprop的优势,能够自动调整每个参数的学习率,实现高效且稳定的收敛。

[0056] 步骤(2)模型训练

[0057] 数据划分:将数据集划分为训练集和验证集,通常按照8:2的比例进行划分。训练集用于模型的训练,验证集用于评估模型的泛化能力,防止过拟合。

[0058] 训练过程:使用训练集数据对MLP模型进行训练,通过迭代优化损失函数,调整模型的权重和偏置。在训练过程中,记录训练损失和验证损失的变化情况,以监控模型的训练进度和性能。

[0059] 步骤(3)L2正则化优化

[0060] 添加正则化项:为了防止模型过拟合,提高模型的泛化能力,在模型的损失函数中

添加L2正则化项。L2正则化通过对模型权重的平方和施加惩罚,促使模型选择较小的权重值,从而降低模型的复杂度。

[0061] 调整正则化参数:通过交叉验证等方法选择合适的正则化参数 α ,以平衡模型的偏差和方差。在本研究中,选择了 $\alpha=0.001$ 作为正则化参数,经过优化后的模型在训练集和测试集上的均方误差和决定系数(R^2)均有所改善。

[0062] S4.模型评估与优化

[0063] 步骤(1)评估指标选择

[0064] 均方误差(MSE):均方误差是衡量模型预测值与真实值之间差异的常用指标,值越小表示模型的预测精度越高。在本研究中,分别计算了训练集和测试集的均方误差,以评估模型在不同数据集上的预测性能。

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

[0065] 决定系数(R^2):决定系数用于衡量模型对数据的拟合程度,取值范围为0到1,越接近1表示模型的拟合效果越好。通过计算训练集和测试集的决定系数,可以直观地了解模型对数据的解释能力。

[0066] 步骤(2)评估结果分析

[0067] 比较训练集和测试集性能:通过比较训练集和测试集的均方误差和决定系数,评估模型是否存在过拟合或欠拟合问题。在本研究中,优化后的模型在训练集和测试集上的均方误差分别为0.00036912和0.00036816,决定系数分别为0.85331226和0.85271417,表明模型具有较好的泛化能力和预测精度。

[0068] 模型优化方向:根据评估结果,进一步分析模型的不足之处,并提出优化方向。例如,如果模型在某些特征上的预测误差较大,可以考虑增加特征工程或调整模型架构;如果模型的泛化能力不足,可以尝试增加正则化强度或调整训练参数。

[0069] S5.洪水风险等级划分

[0070] 步骤(1)K-means聚类算法

假设有一组数据点 $\{x_1, x_2, \dots, x_n\}$,其中每个数据点 $x_i \in \mathbb{R}^d$,表示在d维空间的一个数据点。随机选择K个初始聚类中心 $\{c_1, c_2, \dots, c_K\}$,其中每个 $c_j \in \mathbb{R}^d$ 是一个d维向量。对于每个数据点 x_i ,计算其与每个聚类中心 c_j 的距离(通常使用欧式距离):

$$\text{dist}(x_i, c_j) = \sqrt{\sum_{k=1}^d (x_{ik} - c_{jk})^2}$$

将 x_i 分配到距离最近的聚类中心 c_j ,其中 $j^* = \arg\min_j \text{dist}(x_i, c_j)$ 。对于每个聚类 $j = 1, 2, \dots, K$,更新其聚类中心 c_j ,为其所有分配给该聚类的数据点的均值:

$$c_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i$$

其中, $|C_j|$ 表示聚类j中数据点的数量, C_j 表示分配给聚类j的数据点集合。重复步

骤2和步骤3。重复进行分配和更新阶段,直到达到收敛条件。收敛条件通常是指聚类中心不再发生变化或者变化非常小。最终输出是K个聚类中心 $\{c_1, c_2, \dots, c_K\}$,和每个数据点所属的聚类标签。

[0071] 选择关键特征:根据前面的特征选择结果,选择与洪水风险相关的特征作为聚类的输入变量。在本研究中,选取了多个关键因素作为聚类依据。

[0072] 确定聚类中心:使用K-means聚类算法将洪水事件划分为高、中、低三个风险等级。首先,随机选择K个初始聚类中心,然后通过迭代优化聚类中心,将数据点分配到最近的聚类中心,直到收敛为止。

[0073] 步骤(2)权重评分模型

[0074] 建立权重评分体系:为了量化每个洪水事件的风险级别,建立一个权重评分模型。根据专家知识、历史数据分析及统计检验,为每个关键特征分配权重,以综合考虑各个特征对洪水风险的影响。

[0075] 风险等级划分:根据权重评分模型计算每个洪水事件的风险评分,并将其划分为高、中、低三个风险等级。在本研究中,通过调整关键特征的权重比例,优化了风险等级划分模型,并通过灵敏度分析验证了模型的稳定性和准确性。

[0076] S6.洪水预测与可视化


使用训练好的MLP模型对test.csv中的测试数据集进行洪水发生概率预测,将预测结果记录并保存于submit.csv文件中。绘制测试集洪水概率预测折线图和直方图。折线图展示洪水概率随样本点的变化趋势,直方图展示预测概率的分布情况,使用matplotlib库绘制图表。采用Shapiro-Wilk正态性检验方法评估预测数据的分布特性。先对数据排序生成顺序统计量序列,计算检验统计量

$$W = \frac{(\sum_{i=1}^n a_i x_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$


及相应的p值。经计算,本研究中预测数据的检验统计量W值为0.980,p值为0.000,基于样本数据否定零假设,推断数据不遵循正态分布。使用scipy.stats库进行正态性检验。




图1



相关性分析



随机森林与特征重要性



神经网络回归模型

图2