



(12) 发明专利申请

(10) 申请公布号 CN 121565266 A

(43) 申请公布日 2026. 02. 24

(21) 申请号 202511771074.X

G06N 3/08 (2023.01)

(22) 申请日 2025.11.28

(71) 申请人 新疆大学

地址 830000 新疆维吾尔自治区乌鲁木齐
市水磨沟区新疆大学博达校区南门

(72) 发明人 魏凯 王权 蔡旻诺 马雅慧

(74) 专利代理机构 北京谦佑知识产权代理有限公司 32589

专利代理师 李庆全

(51) Int. Cl.

G16B 40/00 (2019.01)

G16B 50/00 (2019.01)

G06N 3/042 (2023.01)

G06N 3/0442 (2023.01)

G06N 3/0464 (2023.01)


权利要求书2页 说明书10页 附图1页

(54) 发明名称

一种蛋白质功能预测方法、系统、计算机设备及存储介质

(57) 摘要

本发明提供了一种蛋白质功能预测方法、系统、计算机设备及存储介质,属于生物信息学和新药研发技术领域,包括:获取待预测的蛋白质序列;遍历蛋白质序列中的每一个氨基酸,将氨基酸的疏水性、极性和分子量分别映射为音乐元素的音高、音色和时长,生成各氨基酸对应的乐谱序列;对乐谱序列进行编码合成,得到梅尔声谱图;将梅尔声谱图输入预训练的双分支注意力融合模型,得到视觉特征向量和声声学上下文向量;将视觉特征向量和声声学上下文向量进行拼接,得到融合特征向量;根据融合特征向量得到蛋白质功能预测结果。本发明通过视觉特征与声声学上下文向量的融合,实现了结构信息与长程关联的互补,提升了功能预测的完整性与精准度,在减少数据依赖的同时提高了预测效率。



1. 一种蛋白质功能预测方法,其特征在于,包括以下步骤:

获取待预测的蛋白质序列;

遍历蛋白质序列中的每一个氨基酸,将氨基酸的疏水性、极性和分子量分别映射为音乐元素的音高、音色和时长,生成各氨基酸对应的乐谱序列;对所述乐谱序列进行编码合成,得到梅尔声谱图;

从梅尔声谱图中提取从低级到高级的层次化视觉特征,得到视觉特征向量;同时将梅尔声谱图转换为MFCCs时间序列,并对MFCCs时间序列进行加权,生成声学上下文向量;

将视觉特征向量和声声学上下文向量进行拼接操作,得到融合特征向量;

对融合特征向量进行分类处理,输出蛋白质功能预测结果。

2. 根据权利要求1所述的蛋白质功能预测方法,其特征在于,将梅尔声谱图输入预训练的双分支注意力融合模型,输出蛋白质功能预测结果;所述双分支注意力融合模型包括并行的卷积神经网络ConvNeXt-Tiny和引入引入加性注意力机制的双向门控循环单元网络GRU;在ConvNeXt-Tiny和GRU的输出端增加了分类头;所述预训练的双分支注意力融合模型对梅尔声谱图进行处理包括以下步骤:

通过ConvNeXt-Tiny从梅尔声谱图中提取从低级到高级的层次化视觉特征,得到视觉特征向量;同时通过GRU将梅尔声谱图转换为MFCCs时间序列,通过加性注意力机制对MFCCs时间序列进行加权,生成声学上下文向量;

将视觉特征向量和声声学上下文向量进行拼接操作,得到融合特征向量;

通过分类头对融合特征向量进行分类处理,输出蛋白质功能预测结果。

3. 根据权利要求1所述的蛋白质功能预测方法,其特征在于,所述对乐谱序列进行编码合成,得到梅尔声谱图,包括以下步骤:

使用Python库midiutil将所述乐谱序列编码为标准MIDI文件,再通过开源合成器FluidSynth和GeneralUser GS v1.471音色库将标准MIDI文件渲染成WAV格式的音频文件;

使用Python库librosa对WAV格式的音频文件进行处理,通过librosa.feature.melspectrogram函数生成最终的二维声谱图,得到梅尔声谱图。

4. 根据权利要求2所述的蛋白质功能预测方法,其特征在于,所述通过ConvNeXt-Tiny从梅尔声谱图中提取从低级到高级的层次化视觉特征,得到视觉特征向量,具体包括以下步骤:

在ConvNeXt-Tiny网络内部,对梅尔声谱图进行一系列的卷积块操作,每个块包含深度卷积、逐点卷积、层归一化和激活函数操作;

随着数据在网络中逐层前向传播,从图像中提取出从低级到高级的层次化视觉特征,得到视觉特征向量。

5. 根据权利要求2所述的蛋白质功能预测方法,其特征在于,所述通过GRU将梅尔声谱图转换为MFCCs时间序列,通过加性注意力机制对MFCCs时间序列进行加权,生成声学上下文向量,具体包括以下步骤:

从梅尔声谱图中提取梅尔频率倒谱系数MFCCs,将二维图像转换成时间序列数据;

GRU从前到后、再从后到前地扫描整个时间序列,捕捉其中的时序依赖关系和动态模式,输出每个时间步融合了上下文信息的隐藏状态序列;

加性注意力机制对隐藏状态序列中的每一个时间步计算一个重要性权重,根据权重对

所有时间步的隐藏状态进行加权求和,输出一个单一的、固定长度的声学上下文向量。

6. 根据权利要求1所述的蛋白质功能预测方法,其特征在于,所述层次化视觉特征包括低级特征和高级特征;低级特征包括频谱中的边缘、亮度和纹理,高级特征为边缘、亮度和纹理的组合特征。

7. 根据权利要求2所述的蛋白质功能预测方法,其特征在于,所述卷积神经网络ConvNeXt-Tiny和注意力头构成双分支注意力融合模型的视觉分支,所述双向门控循环单元网络GRU和加性注意力机制构成双分支注意力融合模型的声学分支,所述双分支注意力融合模型的训练过程包括:

获取包含已知蛋白质序列及其对应功能标签的数据集,将蛋白质序列转换为训练用梅尔声谱图;

使用生成的梅尔声谱图图像,对包含ConvNeXt-Tiny和分类头的视觉分支进行微调训练;训练采用AdamW优化器,配合余弦退火学习率调度和标签平滑,并使用基于验证损失的提前终止策略来保存最佳模型权重;

对视觉分支的权重通过保存的最佳权重进行初始化;

在训练的前30个周期,视觉分支的参数被完全冻结,仅对新加入的声学分支和最终分类头的参数进行训练;

在前30个周期之后,解冻整个网络,对所有参数进行端到端的联合微调;此过程采用AdamW优化器和余弦退火学习率调度,并应用差异化学习率,为预训练过的视觉骨干设置一个 1×10^{-5} 的学习率,而为新初始化的声学分支和分类器组件设置一个 1×10^{-4} 的学习率。

8. 一种蛋白质功能预测系统,其特征在于,包括:

数据获取模块,用于获取待预测的蛋白质序列;

数据转换模块,用于遍历蛋白质序列中的每一个氨基酸,将氨基酸的疏水性、极性和分子量分别映射为音乐元素的音高、音色和时长,生成各氨基酸对应的乐谱序列;对所述乐谱序列进行编码合成,得到梅尔声谱图;

特征提取模块,用于从梅尔声谱图中提取从低级到高级的层次化视觉特征,得到视觉特征向量;同时将梅尔声谱图转换为MFCCs时间序列,并对MFCCs时间序列进行加权,生成声学上下文向量;

特征融合模块,用于将视觉特征向量和声声学上下文向量进行拼接操作,得到融合特征向量;

预测模块,用于通过分类头对融合特征向量进行分类处理,输出蛋白质功能预测结果。

9. 一种计算机设备,包括存储器、处理器及存储在存储器上的计算机程序,其特征在于,所述处理器执行所述计算机程序以实现权利要求1至7任一项所述方法的步骤。

10. 一种计算机可读存储介质,其上存储有计算机程序,其特征在于,该计算机程序被处理器加载时,能够执行权利要求1至7任一项所述方法的步骤。

一种蛋白质功能预测方法、系统、计算机设备及存储介质

技术领域

[0001] 本发明属于生物信息学和新药研发技术领域,具体涉及一种蛋白质功能预测方法、系统、计算机设备及存储介质。

背景技术

[0002] 蛋白质功能预测是生命科学与人工智能交叉领域的核心任务之一,其目的是通过计算手段快速推断蛋白质的生物功能,如催化反应、信号传导或分子结合等。这一任务的重要性体现在,传统实验测定蛋白质功能成本高、周期长,而基因组测序技术产生的蛋白质序列数据呈指数级增长,两者间的“序列-功能”鸿沟亟待通过高效的计算方法填补,因此开发精准的预测模型对疾病机制研究、药物设计等领域具有关键意义。

[0003] 目前,行业内一种主流的实现方法是基于序列的直接分析法。该方法的核心思路是将蛋白质的氨基酸序列视为“生物文本”,通过One-Hot编码、词嵌入(Embedding)等方式,将每个氨基酸转换为固定维度的数字向量,最终拼接成完整的一维序列向量。随后,该向量会被输入到循环神经网络(RNN)、长短期记忆网络(LSTM)或Transformer等深度学习模型中,让模型从序列数据中自动学习与功能相关的特征模式,进而完成功能分类或预测任务。

[0004] 这种方法的缺陷在于:首先,对空间结构信息的表达能力天然不足,因为蛋白质的功能由其复杂的三维折叠结构决定,而一维序列的线性表示很难有效捕捉到在空间上邻近但在序列上可能相距很远的氨基酸之间的相互作用,导致模型学习到的信息不完整。其次,对长距离依赖关系建模困难,即便使用先进模型,要从稀疏的一维数据中精确学习到跨越数百个氨基酸的微弱关联信号,依然是一个巨大的挑战,且极度依赖海量数据进行预训练,预测效率低。

发明内容

[0005] 为了解决现有方法预测的信息不完整及预测效率低的问题,本发明提供了一种蛋白质功能预测方法。

[0006] 为了实现上述目的,本发明提供如下技术方案:

一种蛋白质功能预测方法,包括:

获取待预测的蛋白质序列;

遍历蛋白质序列中的每一个氨基酸,将氨基酸的疏水性、极性和分子量分别映射为音乐元素的音高、音色和时长,生成各氨基酸对应的乐谱序列;对所述乐谱序列进行编码合成,得到梅尔声谱图;

从梅尔声谱图中提取从低级到高级的层次化视觉特征,得到视觉特征向量;同时将梅尔声谱图转换为MFCCs时间序列,并对MFCCs时间序列进行加权,生成声学上下文向量;

将视觉特征向量和声声学上下文向量进行拼接操作,得到融合特征向量;

对融合特征向量进行分类处理,输出蛋白质功能预测结果。

[0007] 优选地,将梅尔声谱图输入预训练的双分支注意力融合模型,输出蛋白质功能预

测结果;所述双分支注意力融合模型包括并行的卷积神经网络ConvNeXt-Tiny和引入引入加性注意力机制的双向门控循环单元网络GRU;在ConvNeXt-Tiny和GRU的输出端增加了分类头;所述预训练的双分支注意力融合模型对梅尔声谱图进行处理包括以下步骤:

通过ConvNeXt-Tiny从梅尔声谱图中提取从低级到高级的层次化视觉特征,得到视觉特征向量;同时通过GRU将梅尔声谱图转换为MFCCs时间序列,通过加性注意力机制对MFCCs时间序列进行加权,生成声学上下文向量;

将视觉特征向量和声声学上下文向量进行拼接操作,得到融合特征向量;

通过分类头对融合特征向量进行分类处理,输出蛋白质功能预测结果。

[0008] 优选地,所述对乐谱序列进行编码合成,得到梅尔声谱图,包括以下步骤:

使用Python库midiutil将所述乐谱序列编码为标准MIDI文件,再通过开源合成器FluidSynth和GeneralUser GS v1.471音色库将标准MIDI文件渲染成WAV格式的音频文件;

使用Python库librosa对WAV格式的音频文件进行处理,通过librosa.feature.melspectrogram函数生成最终的二维声谱图,得到梅尔声谱图。

[0009] 优选地,所述通过ConvNeXt-Tiny从梅尔声谱图中提取从低级到高级的层次化视觉特征,得到视觉特征向量,具体包括以下步骤:

在ConvNeXt-Tiny网络内部,对梅尔声谱图进行一系列的卷积块操作,每个块包含深度卷积、逐点卷积、层归一化和激活函数操作;

随着数据在网络中逐层前向传播,从图像中提取出从低级到高级的层次化视觉特征,得到视觉特征向量。

[0010] 优选地,所述通过GRU将梅尔声谱图转换为MFCCs时间序列,通过加性注意力机制对MFCCs时间序列进行加权,生成声学上下文向量,具体包括以下步骤:

从梅尔声谱图中提取梅尔频率倒谱系数MFCCs,将二维图像转换成时间序列数据;

GRU从前到后、再从后到前地扫描整个时间序列,捕捉其中的时序依赖关系和动态模式,输出每个时间步融合了上下文信息的隐藏状态序列;

加性注意力机制对隐藏状态序列中的每一个时间步计算一个重要性权重,根据权重对所有时间步的隐藏状态进行加权求和,输出一个单一的、固定长度的声学上下文向量。

[0011] 优选地,所述层次化视觉特征包括低级特征和高级特征;低级特征包括频谱中的边缘、亮度和纹理,高级特征为边缘、亮度和纹理的组合特征。

[0012] 优选地,所述卷积神经网络ConvNeXt-Tiny和注意力头构成双分支注意力融合模型的视觉分支,所述双向门控循环单元网络GRU和加性注意力机制构成双分支注意力融合模型的声学分支,所述双分支注意力融合模型的训练过程包括:

获取包含已知蛋白质序列及其对应功能标签的数据集,将蛋白质序列转换为训练用梅尔声谱图;

使用生成的梅尔声谱图图像,对包含ConvNeXt-Tiny和分类头的视觉分支进行微调训练;训练采用AdamW优化器,配合余弦退火学习率调度和标签平滑,并使用基于验证损失的提前终止策略来保存最佳模型权重;

对视觉分支的权重通过保存的最佳权重进行初始化;

在训练的前30个周期,视觉分支的参数被完全冻结,仅对新加入的声学分支和最终分类头的参数进行训练;

在前30个周期之后,解冻整个网络,对所有参数进行端到端的联合微调;此过程采用AdamW优化器和余弦退火学习率调度,并应用差异化学习率,为预训练过的视觉骨干设置一个 1×10^{-5} 的学习率,而为新初始化的声学分支和分类器组件设置一个 1×10^{-4} 的学习率。

[0013] 本发明还提出一种蛋白质功能预测系统,包括:

数据获取模块,用于获取待预测的蛋白质序列;

数据转换模块,用于遍历蛋白质序列中的每一个氨基酸,将氨基酸的疏水性、极性和分子量分别映射为音乐元素的音高、音色和时长,生成各氨基酸对应的乐谱序列;对所述乐谱序列进行编码合成,得到梅尔声谱图;

特征提取模块,用于从梅尔声谱图中提取从低级到高级的层次化视觉特征,得到视觉特征向量;同时将梅尔声谱图转换为MFCCs时间序列,并对MFCCs时间序列进行加权,生成声学上下文向量;

特征融合模块,用于将视觉特征向量和声学上下文向量进行拼接操作,得到融合特征向量;

预测模块,用于通过分类头对融合特征向量进行分类处理,输出蛋白质功能预测结果。

[0014] 本发明还提供一种计算机设备,包括存储器、处理器及存储在存储器上的计算机程序,所述处理器执行所述计算机程序以实现所述蛋白质功能预测方法中任一项所述的步骤。

[0015] 本发明还提供一种计算机可读存储介质,所述存储介质上存储有计算机程序,该计算机程序被处理器加载时,能够执行所述蛋白质功能预测方法中任一项所述的步骤。

[0016] 本发明提供的蛋白质功能预测方法具有以下有益效果:

本发明先将蛋白质序列转换为包含音高、音色等多维信息的音符,再合成为梅尔声谱图。梅尔声谱图作为二维频谱特征,能通过频率分布与时间维度的耦合,间接映射氨基酸在空间折叠中形成的邻近关系,不同位置氨基酸的相互作用可通过频谱中特定频段的关联模式体现,突破了一维序列的线性局限。同时提取的层次化视觉特征,能从声谱图中捕捉多尺度空间关联,模拟蛋白质三维结构的局部与全局拓扑信息。针对长距离依赖建模难题,本发明将梅尔声谱图转换的MFCCs时间序列,结合对关键时间步加权,强化跨长距离的特征关联。这种设计无需依赖海量数据预训练,通过声学特征的时序连续性与注意力的动态加权,精准捕捉序列中远距离氨基酸的微弱协同信号。

[0017] 最终通过视觉特征与声学上下文向量的融合,实现了结构信息与长程关联的互补,提升了功能预测的完整性与精准度,在减少数据依赖的同时提高了预测效率。

附图说明

[0018] 为了更清楚地说明本发明实施例及其设计方案,下面将对本实施例所需的附图做简单的介绍。下面描述中的附图仅仅是本发明的部分实施例,对于本领域普通技术人员来说,在不付出创造性劳动的前提下,还可以根据这些附图获得其他的附图。

[0019] 图1为本发明实施例1的蛋白质功能预测方法的流程图。

具体实施方式

[0020] 为了使本领域技术人员更好地理解本发明的技术方案并能予以实施,下面结合附图和具体实施例对本发明进行详细说明。以下实施例仅用于更加清楚地说明本发明的技术方案,而不能以此来限制本发明的保护范围。

[0021] 实施例1

本发明的核心任务是解读蛋白质序列这本“天书”,开发并应用了一个量化的、由生物物理学理论驱动的严谨框架,以预测蛋白质序列在生物体内的具体功能。现有技术大多直接分析蛋白质的一维氨基酸文本序列,未能将数据提升到一个能更直观反映内在结构性信息的维度,类似于仅通过阅读文字来判断文章的深层含义。然而,这种方法往往难以捕捉到决定蛋白质功能的关键长距离依赖关系和隐藏模式,就像只读歌词无法体会旋律和情感一样。为了解决这个问题,本发明的核心工作是:在计算机对蛋白质序列进行分析之前,先将其独特的序列信息转化为一门新的“语言”——声学语言。本发明通过一种创新的“声化”技术,将一维的蛋白质序列转换成信息更丰富的二维梅尔声谱图(Mel Spectrogram)。这使得本发明能够利用成熟的图像和音频分析技术,从一个全新的维度来“听”和“看”蛋白质的特征,从而实现对蛋白质功能前所未有的精准预测。

[0022] 基于此,本发明提供了一种蛋白质功能预测方法,本发明的方法包含分类器训练和功能预测两个阶段。具体如图1所示,两个阶段的实现包括以下步骤:

步骤1、获取一个包含大量已知蛋白质序列及其对应功能标签的数据集。标签数据集是监督学习的核心,它作为“标准答案”与模型的预测结果进行比较,通过损失函数计算出两者之间的差距(即损失值)。这个损失值随后被用于通过反向传播算法更新模型的权重,从而驱动模型学习如何正确分类。

[0023] 步骤2、针对数据集中的每一条序列,执行以下步骤:

步骤21、蛋白质声化(量化映射与乐谱生成):遍历蛋白质序列中的每一个氨基酸,将氨基酸的疏水性、极性和分子量分别映射为音乐元素的音高、音色和时长,生成各氨基酸对应的乐谱序列。

[0024] a) 音高(Pitch)的确定:每个音符的MIDI音高编号由其对应氨基酸的疏水性决定,遵循以下核心公式:

$$\text{PitchMIDI} = \text{round}(\text{BASE_NOTE} - (\text{Kyte-Doolittle_Value} \times \text{SCALING_FACTOR}))$$
,其中,PitchMIDI 是MIDI音高编码。BASE_NOTE是参考音高(设置为60,即中央C);Kyte-Doolittle_Value是该氨基酸的疏水性指数;SCALING_FACTOR是比例因子(设置为3.0)。round是Python的内置函数,用于对一个浮点数进行四舍五入取整。因为MIDI音高编号必须是整数,而 $\text{Kyte-Doolittle_Value} \times \text{SCALING_FACTOR}$ 的计算结果是浮点数,所以使用round 函数将其转换为最接近的整数。

[0025] b) 音色(Timbre)的确定:音符的音色由氨基酸的极性决定。本发明使用Zimmerman极性量表,并设定一个阈值(POLARITY_THRESHOLD=8.8)。极性低于或等于8.8的非极性氨基酸,被映射到“明亮”的声学大钢琴(Acoustic Grand Piano)音色;极性高于8.8的极性氨基酸,被映射到“暗淡”的大提琴(Cello)音色。

[0026] c) 时长(Duration)的确定:每个音符的持续时间由其对应氨基酸的分子量动态决定,遵循以下公式: $\text{Duration (in beats)} = \text{Molecular_Weight} / 100.0$ 。其中,

Molecular_Weight指的是氨基酸的分子量。这个公式的目的是将一个生物化学属性(分子量)映射到一个音乐属性(音符时长)。除以100.0是为了将分子量的值缩放到一个适合作为音乐节拍(beats)的范围。例如,丙氨酸(A)的分子量是89.09,它对应的音符时长就是 $89.09 / 100.0 = 0.8909$ 个节拍。

[0027] d) 音量(Velocity)的设定:为排除音量作为干扰变量,所有音符的音量被固定为一个恒定值(MIDI标度下的100)。

[0028] 最终,生成的音高、音色和时长构成了乐谱序列。

[0029] 步骤22、音频合成与梅尔声谱图生成。

[0030] a) 音频合成:使用Python库midiutil将上一步生成的乐谱序列编码为标准MIDI文件,再通过开源合成器FluidSynth和GeneralUser GS v1.471音色库将其渲染成WAV格式的音频文件。

[0031] b) 梅尔声谱图生成:使用Python库librosa对WAV格式的音频文件进行处理,通过librosa.feature.melspectrogram函数生成最终的二维声谱图,即梅尔声谱图。该过程的关键参数设置为:快速傅里叶变换窗口大小(n_fft)为2048,步长(hop_length)为512,梅尔频带数量(n_mels)为128,并使用'hann'窗函数。

[0032] 步骤3、数据增强:在模型训练前,对生成的梅尔声谱图应用SpecAugment技术,在时域和频域上随机进行遮挡,以提升模型的鲁棒性和泛化能力。

[0033] 步骤4、预测模型构建。

[0034] 本发明提出的预测模型为一个双分支注意力融合模型(Dual-Branch Attention Fusion Model),该模型为双分支并行网络,旨在同时从“视觉”和“声学”两个角度对梅尔声谱图进行分析,以获得更全面、更鲁棒的特征表示。具体包括视觉分支、声学分支和融合与分类分支。

[0035] 各分支具体结构如下:

视觉分支(Visual Branch):采用一个在ImageNet上预训练过的卷积神经网络ConvNeXt-Tiny作为骨干,并将其输入通道修改为1,以适应灰度声谱图。该骨干网络的权重不是随机初始化的,而是直接加载了ImageOnlyModel训练好的权重。这使得视觉分支从一开始就具备了强大的频谱图特征提取能力。

[0036] 声学分支(Acoustic Branch):该分支首先从梅尔声谱图中提取一个包含60个梅尔频率倒谱系数(MFCCs)的时间序列。然后,将该序列输入到一个包含2层、隐藏单元为128的双向门控循环单元(Bidirectional GRU)网络中。2层指的是堆叠的GRU层。一个2层的双向GRU意味着:第一层GRU接收MFCC序列作为输入,并输出一个隐藏状态序列。第二层GRU接收第一层GRU的隐藏状态序列作为输入,并输出最终的隐藏状态序列。堆叠多层可以使网络学习到更复杂、更抽象的序列特征。bidirectional=True 意味着在每一层,数据都会被一个前向GRU和一个后向GRU同时处理,以捕捉过去和未来的上下文信息。MFCC序列是一个时间序列(mfccs.T将其形状变为(时间步长, MFCC系数数量))。GRU(Gated Recurrent Unit)是一种循环神经网络(RNN),专门用来处理序列数据。它能够捕捉序列中前后时间步之间的长程依赖关系。在发明通过GRU可以学习到声化后的蛋白质序列中,音符(由MFCCs表示)随时间变化的旋律、节奏和模式。最后,通过一个前馈式加性注意力机制(Feed-forward based Additive Attention Mechanism)对GRU的输出序列进行加权,生成一个单一的声学

上下文向量。

[0037] 融合与分类：将视觉分支提取的特征向量与声学分支生成的上下文向量进行拼接 (Concatenation), 然后送入最终的分类头进行预测。

[0038] 本发明提出的视觉分支使用卷积神经网络 (ConvNeXt-Tiny), 将频谱图作为静态图像来分析, 捕捉频域的空间模式和纹理。与此同时, 声学分支将频谱图转换为MFCCs时间序列, 使用循环神经网络 (GRU), 从时序动态的角度进行分析, 捕捉序列的“节奏”和“旋律”。

[0039] 本发明通过这种“看”和“听”相结合的设计, 让模型能够从两个互补的维度理解蛋白质序列的深层特征。视觉分支关注“什么频率模式存在”, 而声学分支关注“这些模式如何随序列演变”, 实现了信息的协同增强, 比单一模型更强大和鲁棒。

[0040] 同时, 在声学分支中, GRU之后引入了注意力机制。传统的RNN模型会对长序列中的信息有所遗忘。引入注意力机制后, 模型能够自动学习并聚焦于对蛋白质功能最重要的序列片段 (在声学上表现为关键的“音节”或“乐句”)。这不仅提升了预测精度, 也为模型决策提供了潜在的可解释性, 可以探究是哪个区域的特征对最终预测贡献最大。

[0041] 步骤5、两阶段模型训练。

[0042] 阶段一 (视觉骨干预训练):

首先, 仅使用生成的梅尔声谱图图像, 对一个独立的、仅包含ConvNeXt-Tiny视觉骨干和分类头的模型 (ImageOnlyModel) 进行微调训练。此阶段的目标是使在ImageNet上预训练的骨干权重适应声谱图的特有数据分布。训练采用AdamW优化器, 配合余弦退火学习率调度 (Cosine Annealing learning rate schedule) 和标签平滑 (label smoothing, 值为0.1), 并使用基于验证损失的提前终止策略 (early stopping, patience=15) 来保存最佳模型权重。

[0043] 阶段二 (双分支融合模型训练):

接着, 对双分支注意力融合模型的视觉分支的权重通过阶段一保存的最佳权重进行初始化。此阶段的训练采用分步微调 (staged fine-tuning) 策略:

参数冻结训练: 在训练的前30个周期 (epochs), 视觉分支的参数被完全冻结, 系统仅对新加入的声学分支和最终分类头的参数进行训练。

[0044] 联合微调: 在前30个周期之后, 解冻整个网络, 对所有参数进行端到端的联合微调。此过程采用AdamW优化器和余弦退火学习率调度, 并应用差异化学习率 (differential learning rates), 为预训练过的视觉骨干设置一个较小的学习率 (1×10^{-5}), 而为新初始化的声学分支和分类器组件设置一个较大的学习率 (1×10^{-4})。

[0045] 整个阶段二的训练同样受提前终止策略 (patience=15) 的监控, 以防止过拟合。

[0046] 本发明提出的两阶段式迁移学习训练策略不是一次性地端到端训练整个复杂模型, 而是分两步走。

[0047] 第一阶段 (Pre-training): 先单独训练视觉分支, 让其充分适应频谱图这种特定类型的数据分布。这相当于为模型进行一次高效的“领域自适应预训练”。

[0048] 第二阶段 (Fusion Fine-tuning): 将预训练好的视觉分支权重作为初始化, 然后与新加入的声学分支和分类头一起进行联合微调。

[0049] 这种策略使得训练过程更稳定、高效。它确保了强大的视觉特征提取器已经就位, 然后在此基础上再融合时序信息, 避免了从零开始训练所有部分的困难, 能更快地收敛到

更优的性能。

[0050] 步骤6、通过训练后的模型进行蛋白质功能预测。

[0051] 步骤61、接收与声化处理：当接收到一条新的待预测蛋白质序列后，系统严格执行上述分类器训练阶段中的量化声化（步骤21）和梅尔声谱图生成（步骤22）过程，为该序列生成对应的梅尔声谱图，作为双分支注意力融合模型的输入数据。

[0052] 步骤62、执行预测：加载在训练阶段最终保存好的、完整的双分支注意力融合模型，将生成的一张待预测蛋白质序列的梅尔声谱图（被视为单通道的灰度图像，同时用于两个分支）输入训练好的双分支注意力融合模型，模型进行前向传播并输出最终的蛋白质功能预测结果。

[0053] 具体地，通过双分支注意力融合模型进行蛋白质功能预测的过程如下：

第一阶段：视觉分支和声学分支对梅尔声谱图的并行处理：

视觉分支进行特征提取的处理流程如下：

梅尔声谱图首先被送入骨干网络ConvNeXt-Tiny。在网络内部，图像经过一系列的卷积块操作。每个块包含深度卷积、逐点卷积、层归一化（Layer Normalization）和激活函数等操作。

[0054] 随着数据在网络中逐层前向传播，模型会从图像中提取出从低级到高级的层次化视觉特征（即空间特征）。低级特征包括频谱中的边缘、亮度和纹理；高级特征则是这些低级特征组合成的、具有特定意义的复杂模式。

[0055] 最终，骨干网络的输出是一个被高度压缩但信息量丰富的高维视觉特征向量。

[0056] 声学分支进行向量生成的处理流程如下：

a. 特征转换：首先，模型从输入的梅尔声谱图中提取梅尔频率倒谱系数（MFCCs）。这将二维图像转换成了一个时间序列数据。根据附录，每个时间步提取60个MFCCs，形成一个维度为（时间步数，60）的序列。具体地，声学分支通过1D CNN提取局部模式，Bi-GRU建模长程时序关系，Attention机制聚焦关键信息，这三个模块的级联，从MFCC序列中提取出一个高度浓缩且具有代表性的声学特征向量。

[0057] b. 序列建模：该MFCCs序列被送入一个双向门控循环单元GRU网络。GRU从前到后、再从后到前地扫描整个序列，捕捉其中的时序依赖关系和动态模式（即“旋律”和“节奏”）。其输出是每个时间步融合了上下文信息的隐藏状态序列。

[0058] c. 注意力加权：接着，一个注意力机制层作用于GRU的输出序列上。该机制会为序列中的每一个时间步计算一个“重要性”权重，然后根据权重对所有时间步的隐藏状态进行加权求和。

[0059] 输出：一个单一的、固定长度的声学上下文向量（即时序特征）。这个向量是整个MFCCs序列的智能摘要，它更侧重于那些对分类任务最重要的“音节”或“乐句”。

[0060] 第二阶段：特征融合：

将视觉分支输出的视觉特征向量和声学分支输出的声学上下文向量进行拼接操作，得到融合特征向量。本发明的拼接操作是将两个代表同一数据样本但来源不同的特征向量首尾相连，形成一个包含了两种模态信息的、更全面的特征表示。

[0061] 这次拼接形成了一个更长、信息维度更丰富的融合特征向量，它同时包含了频谱图的静态空间模式和动态时序信息。

[0062] 第三阶段:最终分类决策:

将融合特征向量送入一个最终的分类头,输出蛋白质功能预测结果。

[0063] 与ImageOnlyModel类似,该分类头通过线性层将融合特征映射为各类的原始预测分数(Logits)。

[0064] 最终预测结果:

与ImageOnlyModel相同,Logits在训练时用于计算损失,在预测时通过Softmax函数转换为各类别的概率,概率最高的即为最终预测结果。这里的各类别”指的就是酶的七个主要功能类别,即 EC1到EC7。

[0065] 具体的预测流程如下:

第一步:批归一化(Batch Normalization)。

[0066] 输出:归一化后的特征向量,形状不变。

[0067] 第二步:第一个全连接层(Linear Layer)。

[0068] 输出:变换后的特征向量。

[0069] 第三步:ReLU激活函数(Activation Function)。

[0070] 输出:经过非线性激活的特征向量。

[0071] 第四步:Dropout。

[0072] 输出:经过Dropout处理的特征向量。

[0073] 第五步:第二个(也是最后一个)全连接层。

[0074] 输出:原始预测分数向量(Logits)。

[0075] 最终得到的数据和预测结果:

最终得到的数据是Logits。这个向量的每个元素代表模型认为输入样本属于对应类别的原始、未经归一化的置信度分数。例如,一个样本的Logits可能是 [1.2, -0.5, 3.8, 0.1, -2.0, 1.5, 2.9]。

[0076] 得到预测结果的过程:

在预测阶段,对这个Logits向量应用Softmax函数,将其转换为概率分布。例如,上面的Logits经过Softmax后可能变成 [0.08, 0.02, 0.65, 0.04, 0.01, 0.11, 0.09]。

[0077] 最终预测结果就是这个概率分布中概率值最高的那个类别所对应的索引。在上述例子中,第三个元素 0.65 最大,所以模型的预测结果是类别2(因为索引从0开始)。

[0078] 当发现一个新的蛋白质序列时,可以本发明提出的模型来快速预测它可能属于哪个酶的大类,预测结果可以指导后续的实验设计。

[0079] 本发明提出的蛋白质功能预测方法具有以下优势:

多参数量化映射框架:本发明的核心在于建立了一套基于明确生物物理学假设的量化映射框架。区别于任意映射,该框架将蛋白质序列的三种独立的理化性质(疏水性、极性、分子量),分别精确地编码到音乐的三种正交元素(音高、音色、时长)中,使得从一维序列到二维声谱图的转换过程具有坚实的科学内涵和信息完备性。本发明摒弃了任意的启发式规则,转而基于一个核心的生物物理学假设:蛋白质核心中稳定的疏水性残基对应于低频的集体运动。为了在声学上实现这一假设,本发明的框架将更高的疏水性映射为更低的声音音高。同时,本发明利用氨基酸的极性来决定音色,其中非极性残基映射到“明亮”的音色(如钢琴),而极性残基则映射到“暗淡”的音色(如大提琴)。更进一步地,本发明引入了第

三个映射维度:将每个氨基酸的分子量与其对应音符的时长建立正比关系,从而在音乐的节奏层面编码了残基大小的自然规律。

[0080] 通过这种方式,本发明将蛋白质序列首先翻译成包含精确音高、音色和节奏信息的乐谱,再将其渲染成音频并转换为二维声谱图。这个过程不仅是一个简单的维度转换,更关键的是,它将决定蛋白质折叠和功能的多种关键理化信息,以一种全新的、可被深度学习模型高效识别的声学 and 视觉模式编码了下来。

[0081] 双分支、注意力融合的深度神经网络架构:本发明设计了一种创新的异构双分支融合模型。该模型巧妙地结合了:(1) 强大的卷积神经网络(ConvNeXt),用于从声谱图中学习复杂的二维空间视觉模式;(2) 带有注意力机制的循环神经网络(GRU),用于从MFCC序列中捕捉关键的一维时序声学特征。这种架构实现了视觉与听觉信息的优势互补。

[0082] 两阶段迁移学习的训练策略:本发明采用了一种先进的两阶段训练方法。通过先对视觉骨干网络进行领域自适应的预训练,再进行冻结、解冻的精调策略,有效地将大型预训练模型的知识迁移到本发明特定的声谱图数据上,显著提升了模型的训练效率和最终性能。

[0083] 本发明提供的方案可应用于靶向药物的从头设计。具体实施时,首先在计算机中生成一个包含数万条候选肽序列的虚拟库。随后,通过本发明的核心技术——声学二维表征转换,将每条序列转换为一张“声学指纹图”。该转换遵循一套确定性规则:利用Kyte-Doolittle疏水性映射为音乐音高,并基于Zimmerman极性指定为钢琴或大提琴的音色。接下来,将这些代表候选药物的频谱图,输入到一个预训练好的双分支注意力融合深度学习模型中。该模型作为一个高效的“结合活性预测器”,通过其CNN分支识别图中的静态模式,并通过其RNN与注意力分支捕捉序列的动态特征,最终为每个候选肽与靶点的结合可能性打分。基于此分数,本发明进行多轮的迭代优化(选择、突变、再筛选),最终设计出少量预测活性最高的候选药物序列,供后续的湿实验合成与验证。此方法极大地加速了新颖先导化合物的发现过程,将传统数月的筛选周期缩短至数天。

[0084] 基于同一个发明构思,本发明还提出一种蛋白质功能预测系统,包括:
数据获取模块,用于获取待预测的蛋白质序列。

[0085] 数据转换模块,用于遍历蛋白质序列中的每一个氨基酸,将氨基酸的疏水性、极性和分子量分别映射为音乐元素的音高、音色和时长,生成各氨基酸对应的乐谱序列;对乐谱序列进行编码合成,得到梅尔声谱图。

[0086] 特征提取模块,用于从梅尔声谱图中提取从低级到高级的层次化视觉特征,得到视觉特征向量;同时将梅尔声谱图转换为MFCCs时间序列,并对MFCCs时间序列进行加权,生成声学上下文向量。

[0087] 特征融合模块,用于将视觉特征向量和声声学上下文向量进行拼接操作,得到融合特征向量。

[0088] 预测模块,用于通过分类头对融合特征向量进行分类处理,输出蛋白质功能预测结果。

[0089] 上述蛋白质功能预测系统中的各个模块可全部或部分通过软件、硬件及其组合来实现。上述各模块可以硬件形式内嵌于或独立于计算机设备中的处理器中,也可以以软件形式存储于计算机设备中的存储器中,以便于处理器调用执行以上各个模块对应的操作。

[0090] 本发明还提供一种计算机设备,包括存储器、处理器及存储在存储器上的计算机程序,处理器执行计算机程序以实现蛋白质功能预测方法实施例中的步骤。具体实现方法可参见方法实施例,这里不再赘述。

[0091] 进一步地,本发明还提供一种包含指令的非临时性计算机可读存储介质,存储介质上存储有计算机程序。例如包含指令的存储器,上述指令可由计算机设备的处理器执行以完成上述方法。例如,非临时性计算机可读存储介质可以是ROM、随机存取存储器(RAM)、CD-ROM、磁带、软盘和光数据存储设备等。该计算机程序被处理器执行时,能够实现蛋白质功能预测方法实施例中的步骤。具体实现方法可参见方法实施例,这里不再赘述。

[0092] 本领域内的技术人员应明白,本发明的实施例可提供方法、系统或计算机程序产品。因此,本发明可采用完全硬件实施例、完全软件实施例或结合软件和硬件方面的实施例的形式。而且,本发明可采用在一个或多个其中包含有计算机可用程序代码的计算机可用存储介质(包括但不限于磁盘存储器、CD-ROM、光学存储器等)上实施的计算机程序产品的形式。

[0093] 本发明是参照根据本发明实施例的方法、装置(系统)和计算机程序产品的流程图和/或方框图来描述的。应理解可由计算机程序指令实现流程图和/或方框图中的每一流程和/或方框,以及流程图和/或方框图中的流程和/或方框的结合。可提供这些计算机程序指令到通用计算机、专用计算机、嵌入式处理机或其他可编程数据处理设备的处理器以产生一个机器,使得通过计算机或其他可编程数据处理设备的处理器执行的指令产生用于实现在流程图一个流程或多个流程和/或方框图一个方框或多个方框中指定的功能的装置。

[0094] 这些计算机程序指令也可存储在能引导计算机或其他可编程数据处理设备以特定方式工作的计算机可读存储器中,使得存储在该计算机可读存储器中的指令产生包括指令装置的制造品,该指令装置实现在流程图一个流程或多个流程和/或方框图一个方框或多个方框中指定的功能。

[0095] 这些计算机程序指令也可装载到计算机或其他可编程数据处理设备上,使得在计算机或其他可编程设备上执行一系列操作步骤以产生计算机实现的处理,从而在计算机或其他可编程设备上执行的指令提供用于实现在流程图一个流程或多个流程和/或方框图一个方框或多个方框中指定的功能的步骤。

[0096] 应当指出,以上所述具体实施方式可以使本领域的技术人员更全面地理解本发明创造,但不以任何方式限制本发明创造。因此,尽管本说明书和实施例对本发明创造已进行了详细的说明,但是,本领域技术人员应当理解,仍然可以对本发明创造进行修改或者等同替换;而一切不脱离本发明创造的精神和范围的技术方案及改进,其均涵盖在本发明创造专利的保护范围当中。不应将权利要求中的任何附图标记视为限制所涉及的权利要求。任何熟悉本领域的技术人员在本发明披露的技术范围内,可显而易见地得到的技术方案的简单变化或等效替换,均属于本发明的保护范围。




图 1