



(12) 发明专利申请

(10) 申请公布号 CN 121302351 A

(43) 申请公布日 2026. 01. 09

(21) 申请号 202511402576.5

(22) 申请日 2025.09.28

(71) 申请人 新疆大学

地址 830046 新疆维吾尔自治区乌鲁木齐
市天山区胜利路666号

(72) 发明人 赵洪田 张佳琳 常钰晗 闫佳瑶
王一权 邓斯尹

G06N 3/09 (2023.01)

G06N 5/022 (2023.01)

G06F 40/284 (2020.01)

G06F 40/295 (2020.01)

G06F 40/30 (2020.01)

G06F 18/22 (2023.01)

G06F 18/241 (2023.01)

G06F 18/25 (2023.01)

(51) Int. Cl.

G06F 21/54 (2013.01)

G06F 21/62 (2013.01)

G06F 21/10 (2013.01)

G06N 3/045 (2023.01)

G06N 3/042 (2023.01)

G06N 3/0442 (2023.01)

G06N 3/0475 (2023.01)

G06N 3/0499 (2023.01)

权利要求书2页 说明书3页 附图2页

(54) 发明名称

一种用于文生图隐私保护的仿生免疫防御
算法

(57) 摘要

本发明涉及一种应用于文生图隐私保护方面的仿生免疫动态防御算法。针对现有生成式模型在隐私保护和对抗性攻击防御存在的局限,本发明通过模拟生物免疫机制,实现对隐私风险的主动、自适应防护,主要包括:利用表观遗传编码技术对提示词进行处理,以增强文本嵌入的隐私保护能力;通过隐私检测单元识别并评估潜在的隐私风险,并根据风险等级动态扰动文生图模型的潜在空间;利用免疫记忆模块存储并召回历史威胁模式,以提升对重复攻击的响应效率;当风险持续高于预设阈值时,触发组件操作机制,选择性地调整或禁用模型组件,以快速阻断高危生成。与现有技术相比,本发明能够在保持图像生成质量的同时显著提升隐私保护能力和对抗性鲁棒性,实现性能与安全性的平衡。

1.一种文生图隐私保护方法,包括:

S1.提示词表观遗传编码

对用户输入的文本提示词进行编码,生成隐私保护的文本嵌入;

S2.隐私风险评估

将隐私保护的文本嵌入输入隐私检测单元(PDU),在PDU执行以下操作:识别文本提示词中的命名实体,并基于知识图谱构建概念图,将概念图的图特征和所述文本提示词的文本特征进行多头注意力机制融合,评估隐私风险,并输出隐私风险评分;

S3.潜在空间动态扰动

将隐私风险评分输入安全增强单元(SEU),SEU基于所述隐私风险评分及当前时间步计算噪声强度,将噪声注入文生图模型;

S4.免疫记忆学习与召回

当PDU识别出高风险提示词时,将风险特征存储至免疫记忆模块(IMM),IMM存储风险特征、查询记忆库、在高相似度时输出召回信号;当风险评分超过预设阈值时,触发组件操作机制以调整或禁用模型组件。

2.一种文生图隐私保护装置,其特征在于,包括:表观遗传编码模块(210),用于对用户输入的文本提示词进行编码以生成隐私保护的文本嵌入;隐私检测单元(220),与所述表观遗传编码模块(210)连接,用于识别所述文本提示词中的命名实体,基于知识图谱构建概念图,结合所述概念图的图特征、所述文本提示词的文本特征及敏感关键词匹配结果评估隐私风险,并输出隐私风险评分;安全增强单元(230),与所述隐私检测单元(220)连接,用于基于所述隐私风险评分及当前时间步计算噪声强度,将静态噪声与基于朗之万动力学的噪声组合后注入文生图模型的潜在变量;免疫记忆模块(240),与所述隐私检测单元(220)及安全增强单元(230)连接,用于当隐私风险评分超过第三预设阈值时存储风险特征,基于当前提示词特征查询记忆库,若匹配相似度超过第四预设阈值则向所述安全增强单元(230)传递召回信号;组件操作单元(250),与所述隐私检测单元(220)连接,用于持续监测所述隐私风险评分,当连续隐私风险评分超过第五预设阈值或累积隐私风险评分超过第六预设阈值时,选择性地调整或禁用所述文生图模型的目标组件;以及

基础生成模型(260),与所述表观遗传编码模块(210)、安全增强单元(230)及组件操作单元(250)连接,用于基于处理后的文本嵌入和潜在空间生成图像。

3.根据权利要求1中所述的方法,其特征在于,编码通过归一化流模型实现,归一化流模型对原始文本嵌入执行可逆变换,可逆变换通过耦合层序列实现,每个耦合层对输入向量的预定维数子集执行尺度变换和偏移变换。

4.根据权利要求1中所述的方法,其中,IMM执行以下操作:基于当前提示词特征查询记忆库,若匹配相似度超过预设阈值,则向所述SEU传递召回信号,以及通过PDU持续监测所述隐私风险评分,若连续隐私风险评分超过第一预设阈值或累积隐私风险评分超过第二预设阈值,则触发组件操作机制,该机制包括但不限于降低目标注意力头的权重系数、冻结目标神经网络层的参数更新或激活目标残差连接的屏蔽门控,以选择性地调整或禁用所述文生图模型的目标组件。

5.根据权利要求2所述的装置,其中,表观遗传编码模块(210)包括归一化流模型,其中,归一化流模型包含由仿射变换层构成的耦合器序列;免疫记忆模块(240)包含图神经网络

络,所述图神经网络用于提取风险特征并基于余弦相似度计算特征匹配度。

6.根据权利要求1所述的方法或权利要求2所述的装置,其特征在于,隐私风险评分基于加权函数计算,所述加权函数的输入包括:图特征中心度得分、敏感实体出现频次以及敏感关键词匹配结果;所述目标组件的禁用方式选自以下方式中的任意一种或其组合:降低目标注意力头的权重系数,冻结目标神经网络层的参数更新,激活目标残差连接的屏蔽门控;所述静态噪声服从高斯分布 $N(0, \sigma_s)$,所述基于朗之万动力学的噪声求解随机微分方程生成,以模拟扩散过程中的随机扰动。

7.根据权利要求3所述的方法或权利要求4所述的装置,其特征在于,所述噪声强度通过下列公式计算: $\sigma_t = \lambda * RiskScore + \mu * (1 - e^{(-\frac{t}{\tau})})$ 其中 λ 、 μ 为比例因子, τ 为时间衰减常数,t表示当前时间步。

8.根据权利要求5所述的方法或装置,其特征在于,所述加权函数为: $Score = \alpha * Centrality + \beta * Frequency + \gamma * Match$,其中 α 、 β 、 γ 为预设加权系数,且 $\alpha + \beta + \gamma = 1$ 。

9.根据权利要求7所述的方法或装置,其特征在于,所述比例因子 λ 的取值区间为[0.2, 0.5], μ 的取值区间为[0.1, 0.3]。

10.根据权利要求9所述的装置,其中,当检测到第三预设数量的连续高风险事件而激活目标残差连接的屏蔽门控。

一种用于文生图隐私保护的仿生免疫防御算法

技术领域

[0001] 本发明涉及人工智能安全领域,特别是生成式人工智能模型(文本到图像生成模型)中的隐私保护、对抗性攻击防御及内容安全管理技术。

背景技术

[0002] 近年来,随着生成式人工智能(Generative AI)技术的飞速发展,特别是文本到图像(Text-to-Image)模型的广泛应用,其在艺术创作、内容生成等领域展现出广泛应用前景。然而,这些模型在带来便利的同时,也引发了日益增长的隐私泄露和内容安全风险。例如,当用户输入包含个人身份信息、受版权保护的图像描述或敏感主题的提示词时,模型可能几乎原样地复现训练数据中的受版权保护的艺术作品、个人照片或其他敏感图像,这构成了严重的版权侵权和隐私泄露。现有技术中,针对生成式模型的隐私保护方法主要包括数据脱敏、差分隐私、同态加密等。这些方法通常在数据预处理阶段或模型训练阶段进行,具有一定的局限性,如静态性、性能与隐私的权衡、对抗性攻击、计算开销大等。

[0003] 目前应对生成式人工智能模型隐私与版权风险的技术手段,普遍存在计算开销巨大、易损害模型通用性、或防御机制被动滞后等局限性。近年来,随着人工智能仿生学思想的融合,本发明通过模拟生物免疫机制,为解决该问题提供了一种全新的主动防御思路。本文所提出的仿生免疫防御方法,引入生态学中的“宿主-共生体”模型,其中,以扩散模型为基础的主题生成器模拟宿主网络,构建包含隐私检测单元和安全增强单元的并行模块的共生防护层,通过模拟生物体免疫系统中的识别、响应、记忆和适应过程,并在此基础上引入对抗博弈的进化反馈机制,从而持续优化隐私保护与生成质量之间的平衡。该方法不仅能主动、从根源上阻止特定敏感内容的生成,而且最大限度地保留了模型原有的通用创作能力,有效解决了传统方法在成本、效率和性能维护上的矛盾。综上,现有技术在防护策略的动态适应性、输入侧敏感信息识别、生成质量与隐私保护的平衡、评估体系的科学性等方面仍存在诸多不足,亟需一种能够主动、动态、全流程防护的新型生成式AI安全机制。

发明内容

(一)要解决的技术问题

[0004] 针对现有生成式人工智能模型在隐私保护方面存在的静态防御机制适应性差、隐私保护与生成质量难以兼顾、对动态威胁响应滞后及缺乏持续学习与进化能力的问题,本发明提供一种仿生免疫防御方法及系统,用于实现动态自适应且具有持续进化能力的隐私防护。

(二)技术方案

[0005] 本发明提供一种用于文生图隐私保护的仿生免疫防御方法,包括以下协同工作的核心模块:(1)表观遗传编码模块:利用基于归一化流的可逆变换,将原始文本嵌入映射至隐私空间,通过引入随机性及在解码时不可逆性,提升语义信息的抗逆向工程能力,有效防止敏感信息泄露;(2)隐私检测单元:通过构建概念图与多模态特征融合,对提示词中的敏

感实体、概念关联及关键词匹配进行深度分析,输出动态风险评分;(3) 安全增强单元:根据风险评分在扩散模型潜在空间注入强度自适应的噪声,以模糊敏感信息在潜在空间中的表示,从而阻止敏感图像的生成;(4) 免疫记忆模块:存储历史风险模式并基于相似度召回防御策略,实现对已知威胁的快速响应和防御策略的持续优化;(5) 细胞凋亡机制:当累计风险超过阈值时,选择性调整模型组件以阻断高危生成,例如降低特定注意力头的权重或冻结相关网络层参数,以防止模型生成高风险内容。

有益效果

[0006] 与现有技术相比,本发明能够:(1) 通过表观遗传编码与动态噪声注入的协同作用,在保障图像生成质量的同时,显著提升语义隐私保护强度,实现隐私保护与生成性能的有效平衡;(2) 利用免疫记忆模块实现防御策略的持续进化,增强对重复攻击模式的响应效率,提高系统的长期鲁棒性;(3) 通过细胞凋亡机制对不可控风险实施快速阻断,有效降低系统性隐私泄露风险,为系统提供紧急情况下的安全保障;(4) 建立从前置编码、过程扰动到后端组件控制的分层防御架构,实现对隐私风险的全流程、多粒度、自适应防护。

附图说明

[0007] 图1为本发明一种用于文生图隐私保护的仿生免疫防御算法的整体架构示意图;

[0008] 图2为本发明一种用于文生图隐私保护的仿生免疫防御算法的算法详细步骤图。

具体实施方式

[0009] 实施例1:表观遗传编码模块,输入提示词后,执行表观遗传编码以增强文本嵌入层隐私保护。具体包括:文本嵌入生成:采用预训练文本编码器将原始文本提示词转换为高维嵌入向量 $X_{raw} \in \mathbb{R}^{L \times D_{text}}$, 其中L为序列长度, D_{text} 为文本嵌入维度。该编码器包含分词器与编码器:分词器将文本转换为token ID序列;Transformer编码器将token ID序列转换为上下文相关的嵌入向量。归一化流编码:通过可逆的归一化流模型将 X_{raw} 映射至隐私保护潜在空间。将 X_{raw} 展平为 $N \times D_{text}$ 矩阵(其中N为批次大小与序列长度的乘积),经多个耦合层堆叠的RealNVP模型进行变换。单个耦合层变换为 $y_2 = x_2 \odot \exp(s(x_1)) + t(x_1)$, 其中 x_1, x_2 为输入向量分割子部, $s()$ 和 $t()$ 为由神经网络实现的尺度函数与偏移函数。编码后嵌入编码后提示词向量 $X_{encoded}$ 作为后续模块输入。实现时可采用 `epigenetic_encoding.epigenetic_encoding.RealNVP` 类,其中dim参数设置为 D_{text} , hidden_dim与num_coupling_layers根据模型复杂度调整。

[0010] 实施例2:隐私检测与安全增强单元

[0011] 隐私检测单元(PDU)执行以下操作:

[0012] (1) 实体识别:在表观遗传编码前,采用预训练NER模型(如spaCy的 `en_core_web_sm`) 识别原始提示词中的敏感实体,包括但不限于人名、地点、组织机构、特定产品名称、受版权保护的艺术品名称或任何可能导致个人身份识别或版权侵权的关键词;

[0013] (2) 概念图构建:通过API调用外部知识图谱(如ConceptNet)构建实体关系图,以捕捉提示词中识别出的实体之间的语义关联、层级关系和潜在的隐私风险传播路径;

[0014] (3) 风险评估:利用图神经网络处理概念图生成节点特征(GraphFeatures),同时匹配预设敏感关键词列表(KeywordMatch);将图特征、文本嵌入特征(TextFeatures,即

X_{encoded} 的特征)及关键词匹配特征融合后输入多层感知机(MLP)分类器,并通过Sigmoid激活函数,输出隐私风险评分:

$$R = \text{Sigmoid}(\text{MLP}(\text{Concat}(\text{GraphFeatures}, \text{TextFeatures}, \text{KeywordMatch})))$$

其中 $R \in [0, 1]$ 。 GraphFeatures 可通过GCN从概念图中提取,反映实体间的结构化隐私风险; TextFeatures 可使用 X_{encoded} 的池化表示,捕捉文本的语义隐私风险; KeywordMatch 为敏感关键词匹配的二值或加权结果,指示直接的敏感信息。

[0015] 安全增强单元(SEU)根据R值执行动态噪声注入:

[0016] (1) 在扩散模型第t步获得 z'_{t-1} 后;

[0017] (2) 计算噪声强度 $\alpha(R, t) = k \cdot R \cdot f(t)$,其中k为可调系数, $f(t)$ 为时间相关函数,用于调整噪声强度随扩散步数的变化,如 $f(t) = t/T_{\text{max}}$ 或 $f(t) = \exp(-t/\tau)$, $t \in [0, T_{\text{max}}]$, T_{max} 为扩散模型的总步数, τ 为时间衰减常数,用于控制衰减速度;

[0018] (3) 生成与 z'_{t-1} 同维随机噪声 δ_t ,输出增强潜在变量: $z_{t-1}^{\text{enhanced}} = z'_{t-1} + \alpha(R, t) \cdot \delta_t$ 。当免疫记忆模块(IMM)提供记忆信号时,SEU将其整合至噪声生成过程。

[0019] 实施例3:免疫记忆模块(IMM),执行以下操作:

[0020] (1) 记忆存储:当 $R > R_{\text{threshold}}$ 时,其中 $R_{\text{threshold}}$ 为预设阈值,提取PDU输出特征向量存入记忆库;若新事件与现存记忆相似度超过阈值 θ_1 ,则更新对应记忆权重,以强化对重复威胁的防御。风险特征向量可包括文本嵌入特征、概念图特征及风险评分等,相似度计算可采用余弦相似度或其他距离度量;

[0021] (2) 记忆查询:对新输入计算其风险特征与记忆库的相似度,若超过阈值 θ_2 则召回加权记忆信号,召回信号可用于通知SEU调整噪声注入参数,或直接触发组件操作单元的防御策略,实现快速响应;

[0022] (3) 记忆遗忘:采用以下机制任意一种或其组合:按时间衰减记忆权重、基于访问频率淘汰低优先级记忆、当存储达预设容量时,采用

LRU/LFU策略移除条目。

[0023] 实施例4:凋亡机制,执行以下连续监测:

[0024] (1) 当连续计数C次 $R > R_{\text{triggerthreshold}}$ (当连续超过次数超过系统预设容忍值时),或在时间窗口 T_w 内 $R > R_{\text{triggerthreshold}}$ 时进入预警状态,其中 $R_{\text{triggerthreshold}}$ 为触发阈值;

[0025] (2) 触发凋亡后执行:降低生成模型中高文本依赖性注意力层的权重、选择性跳过扩散步骤并临时禁用高风险模块;

[0026] (3) 当 $\bar{R}$ 持续 T_s 时间低于安全阈值或经 T_r 时间后,逐步恢复组件功能。




图1




图2